

# Protocolo de Tesis

Cuantificación de incertidumbre bayesiana aproximada en problemas inversos de ODE

---

César Isaí García Cornejo

Asesor: Dr. José Andrés Christen Gracia

CIMAT

# Introducción

---

Los modelos que pretendan describir los fenómenos naturales deben ser causales, respetando orden entre causa y efecto.

Típicamente, los modelos matemáticos precisan de condiciones iniciales o parámetros para caracterizar la unicidad en su solución. Tales parámetros se conocen como parámetros del modelo y se interpretan como causas del fenómeno modelado. Mientras que la solución del modelo se interpreta como la predicción del fenómeno, que se asocia a los efectos.

# Introducción

El proceso anteriormente descrito se llama problema directo o *forward problem* ya que sigue la dirección de causalidad. Sin embargo, es interesante también el problema inverso, dada ciertas observaciones de las cualidades de un fenómeno (efectos), **¿es posible calcular las causas del modelo que rige el fenómeno?**



# Antecedentes

---

Estudio de un sistema físico:


## 1: Parametrización



## 2: Modelación directa



## 3: Problema inverso



## El problema directo:

Predecir los valores de las observables físicos  $\mathbf{d}$  que corresponde a un modelo  $\theta$

$$\theta \mapsto \mathbf{d} = \mathbf{F}(\theta)$$

Incertidumbre de las mediciones e imperfecciones del modelo [2].

# Ejemplos

## Resorte sujeto a fricción

Sea  $x(t)$  la posición

$$m\ddot{x} = -kx + b\dot{x}$$

## Forward map

$$\theta = (k, b) \mapsto F(\theta) = x(t)$$

## Caída sujeto a fricción

Sea  $x(t)$  la posición

$$m\ddot{x} = g - b\dot{x}$$

## Forward map

$$\theta = (g, b) \mapsto F(\theta) = x(t)$$

## Crecimiento poblacional

Sea  $P(t)$  el tamaño de población

$$\frac{dP}{dt} = rP \left(1 - \frac{P}{K}\right)$$


## Forward map

$$\theta = (r, K) \mapsto F(\theta) = P(t)$$



## La distribución posterior

$$\pi(\theta|x^n) \propto \mathcal{L}(\theta|x^n)\pi(\theta)$$



Procedimiento:

- **Observaciones:**  $(x_1, t_1), (x_2, t_2), \dots, (x_n, t_n)$
- Cuantificar el error mediante la relación

$$x_i = F_{\theta}(t_i) + \varepsilon_i, \quad i = 1, \dots, n$$

- Un supuesto convencional sobre los errores

$$\varepsilon_i \sim N(0, \sigma^2)$$

## Distribución posterior

$$\begin{aligned}\pi(\theta|x^n) &\propto \mathcal{L}(\theta|x^n)\pi_{\Theta}(\theta) \\ &\propto \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2} (x_i - F_{\theta}(t_i))^2\right) \pi_{\Theta}(\theta) \\ &\propto \left(\frac{1}{2\pi\sigma^2}\right)^{n/2} \exp\left(\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - F_{\theta}(t_i))^2\right) \pi_{\Theta}(\theta)\end{aligned}$$

donde  $\theta = (\theta_1, \dots, \theta_m)$ .


## Simular por métodos Monte Carlo

- Se simula por MCMC Metropolis-Hastings [1].


## Ejemplo

---


# Resorte sujeto a fricción




## Trayectoria de caminata aleatoria




Distribuciones a priori y posterior para  $k$







Curva estimada ( $n = 30$ )




# Objetivos

---

A pesar de que el análisis previo nos permite obtener estimaciones bastante precisas para el problema inverso. Sin embargo, son **computacionalmente pesadas**, esto debido a que a cada paso en la cadena requiere que se solucione el problema forward, es decir, se resuelven ecuaciones diferenciales tantas veces como se deje correr la cadena.

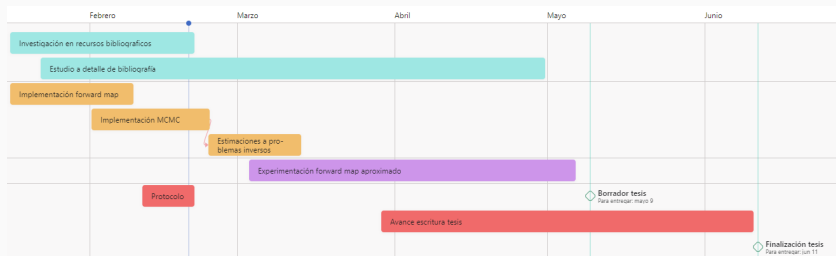
- Se desea encontrar una especie de *interpolación* para solo solucionar una cantidad pequeña de veces el problema forward y para cada punto en el espacio de parámetros se pueda aproximar la solución en función de las soluciones con parámetros cercanos.



# Plan de trabajo

---

# Plan de trabajo





C. P. Robert, G. Casella, and G. Casella.  
***Monte Carlo statistical methods, volume 2.***  
Springer, 1999.



A. Tarantola.  
***Inverse problem theory and methods for model parameter estimation.***  
SIAM, 2005.